

[2026]

4bit

데이터톤 결과 보고서

20233593 박민규
20232095 유지원
20242370 이승환
20233591 정민혁

[목차]

01 | 문제 정의

02 | 목표 및 해결전략

03 | 데이터 소개

04 | 데이터 전처리

05 | 데이터 분석

06 | 아이디어 개요

07 | 모델링 / 분석 방법

08 | 모델링 결과 해석 & 활용 방안

09 | 한계점 및 개선 방향

10 | 결론 (Takeaway)




연구적 관점

- 현상: 전통적 수치해석 중심에서 AI 기반 데이터 분석 체계로 급격히 이동 중.
- 문제: '분석형 AI'에서 '생성형 AI'로 넘어가는 기술적 변곡점을 논문 홍수 속에서 적시에 포착하기 불가능.



데이터적 관점

- 현상: 키워드(KYWD) 결측치가 26.38%에 달해 단순 통계만으로는 정확한 트렌드 파악이 어려움.
- 문제: 데이터 빈틈으로 인해 기술의 실제 파급력을 과소평가하거나 왜곡된 분석 결과 도출 위험.




실용적 관점

- 현상: 연구자/기관 분석 분리로 특정 기술의 핵심 전문가 파악 및 학계/산업계 중심 여부 판단 곤란.
- 문제: 연구 트렌드를 아는 것과 실제 수행을 위한 '네트워킹 인사이트' 사이의 심각한 단절 존재.

[목표 및 해결전략]

목표



1. [데이터 정밀 복원]

26.38%에 달하는 키워드 결측치를 보간하여 분석 결과에 대한 신뢰성 확보

2. [4-Track 전처리]

연구자, 키워드, 기관, 분야별로 특화된 전처리 로직을 설계하여, 질문 하나에 대해 "어떤 분야의 어떤 전문가가 어느 기관에서 연구하는지"를 한 번에 답변할 수 있는 "4bit 분석 엔진"의 신뢰도를 극대화함.

3. [4bit Pathfinder 모델]

키워드 입력 시 최적 연구 분야, 전문가, 기관 즉각 추천

급변하는 공학 기술 패러다임(방법론→AI) 정밀 포착

과거 데이터 조회를 넘어 연구 효율성을 극대화하는 시스템 구축


[목표 및 해결전략]

1. 데이터 정밀 복원 : 제목 기반 컨텍스트 마이닝

- 결측치 26.38%를 단순 제거 대신 정보 복원 전략으로 해결함
- master vocab을 단어 길이 기준 정렬하고 제목 내 복합 공학 명사 우선 추출 → 의미 파편화 방지함
- 키워드 누락 데이터에서 NODE_TITLE 기반 핵심 용어 역추적하여 데이터 충전을 94% 달성 → 통계적 유의성 확보함

2. 입체적으로 분석 설계: 4-Track 모듈형 전처리 파이프라인

- 연구 생태계를 4개 축으로 분해하여 다각도 인사이트 확보함



3. 4bit PathFinder 모델 제작

- ko-sroberta-multitask 모델을 활용하여 단순 키워드 매칭을 넘어선 기술적 맥락 이해 및 의미론적 유사도 분석 구현
- Facebook AI Similarity Search(Faiss) 라이브러리를 연동하여 62,199건의 대규모 데이터셋에서도 밀리초 단위의 실시간 탐색 성능 확보
- 키워드 불일치 상황에서도 사용자의 질문과 가장 연관성이 높은 논문-연구자-기관을 입체적으로 연결하는 추천 로직 탑재

[데이터 소개]

- 데이터명: SSU Datathon 2025 공학 분야 기술 노드 데이터 (NODE_LIST)
- 데이터 규모: 총 62,199건의 논문 및 학술 자료 메타데이터
- 시간적 범위: 2021년 ~ 2025년 (최신 연구 동향 반영)
- 데이터 성격: 논문 제목, 저자, 소속 기관, 키워드 등 연구 성과를 식별할 수 있는 13개 핵심 필드로 구성된 데이터셋

```
import pandas as pd
import json
import re
import matplotlib.pyplot as plt
from collections import Counter
!pip install konlpy
!pip install soynlp
from soynlp.noun import LRNounExtractor_v2
from konlpy.tag import Okt
import html
import os
import numpy as np

# 구글 드라이브 파일 경로
file_path = '/content/drive/MyDrive/SSU_Datathon2025_공학분야_62199.json'

# JSON 로드 및 리스트 추출
with open(file_path, 'r', encoding='utf-8') as f:
    raw_data = json.load(f)
df = pd.DataFrame(raw_data['NODE_LIST'])

# 데이터 기본 정보 출력 (보고서 1단계 내용)
print(f"전체 데이터 건수: {len(df)}건") # 62,199건 확인
print(df.info()) # 13개 컬럼 확인
```

전체 데이터 건수: 62199건

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 62199 entries, 0 to 62198

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	NODE_ID	62199 non-null	object
1	IPRD_NM	62199 non-null	object
2	PLCT_NM	62199 non-null	object
3	NODE_TTLE	62199 non-null	object
4	NODE_TTLE_EN	62199 non-null	object
5	PBSH	62199 non-null	object
6	NODE_LINK	62199 non-null	object
7	NODE_CLSS_01	62199 non-null	object
8	NODE_CLSS_02	62199 non-null	object
9	AUTR_NM	62199 non-null	object
10	KYWD	45788 non-null	object
11	ABST_KR	62199 non-null	object
12	ABST_EN	62199 non-null	object

dtypes: object(13)

memory usage: 6.2+ MB

None

[데이터 소개]

핵심 속성 (Feature) 분류

- 기술(Technology): NODE_TTLE(제목), KYWD(키워드) → 연구 주제 및 기술 스택 식별
- 인적 자원(Human): AUTR_NM(저자), PLCT_NM(발행기관/소속) → 전문가 및 네트워크 분석
- 분류 체계(Category): NODE_CLSS_01/02 → 공학 세부 전공별 클러스터링 기반
- 연속성(Time): PBSH(발행일) → 연도별 트렌드 및 기술 성장률 산출 기초

```
# 분석에 필요한 컬럼명 매칭 및 전처리
name_col, affil_col, year_col, title_col = 'AUTR_NM', 'PLCT_NM', 'PBSH', 'NODE_TTLE'

df[name_col] = df[name_col].fillna('Unknown').astype(str).str.strip()
df[affil_col] = df[affil_col].fillna('Unknown Institution').astype(str).str.strip()

# 연도 추출 (정규식 사용)
df['year_clean'] = df[year_col].astype(str).str.extract(r'(\d{4})')[0]
df['year_clean'] = pd.to_numeric(df['year_clean'], errors='coerce').fillna(0).astype(int)
```

데이터 로드 완료: 62,199건
연구자 전수 분석 시작

분석 완료! 필터링 후 49,584명의 연구자를 식별했습니다.

	AUTR_NM	PLCT_NM	전체논문수	최근연구연도	최근3년_활동량	동명이인_의심_수
0	이진천	설비저널	61	2025	37	1
1	김의중, 조흥현	설비저널	60	2025	36	1
2	김현	대한토목학회지	59	2025	35	4
3	신현배	기계저널	59	2025	35	1
4	조흠	대한토목학회지	59	2025	35	1
5	이창식	오토저널	57	2025	35	2
6	이상운	한국인터넷방송통신학회 논문지	54	2025	34	1
7	박만재	기계저널	33	2025	29	1
8	문지영	대한토목학회지	26	2025	25	1
9	구상	한국자동차공학회논문집	31	2025	22	2
10	김태용	오토저널	22	2025	22	3
11	백우진	대한토목학회지	22	2024	22	1
12	김동권	설비저널	30	2025	18	1
13	김정진	기계저널	30	2025	18	2
14	정민영	대한토목학회지	30	2025	18	2
15	김종현	한국컴퓨터정보학회논문지	22	2025	18	7
16	서사범	철도저널	29	2025	17	1
17	송달호	철도저널	29	2025	17	1
18	심종성	대한토목학회지	29	2025	17	2
19	유지이	기계저널	29	2025	17	1

【 데이터 전처리 】

- KYWD 컬럼 결측치(26.38%)
- 결측치 처리 : KYWD가 존재하지 않는 논문들에 대하여 제목에서의 단어 추출을 통해 결측치를 보간하고자 함

```
# 결측치 비율 확인
null_percent = df.isnull().sum() / len(df) * 100
print("\n--- 필드별 결측치 비율 ---")
print(null_percent[null_percent > 0])
```

```
--- 필드별 결측치 비율 ---
KYWD      26.384669
dtype: float64
```


【 데이터 전처리 】

결측치 보간

STEP 1. 단어 수동 매핑

동일한 의미를 가진 단어지만
다르게 표현된 단어들을 매핑하여
같은 단어로 집계되도록 함.
(인공지능, artificial intelligence, ai)

```
mapping_dict = {
    '인공지능': 'ai', 'artificial intelligence': 'ai',
    '딥러닝': 'deep learning', 'deep learning': 'deep learning', 'deep neural network': 'deep learning',
    '머신러닝': 'machine learning', '기계학습': 'machine learning', '기계 학습': 'machine learning',
    '알고리즘': 'algorithm', 'algorithm': 'algorithm',
    '데이터': 'data', 'data': 'data', '빅데이터': 'data', 'big data': 'data', 'bigdata': 'data',
    'neural network': 'neural network', 'artificial neural network': 'neural network', '인공신경망': 'neural network',
    '조선': 'shipbuilding', '선박': 'shipbuilding', 'shipbuilding': 'shipbuilding',
    '자동차': 'automobile', 'vehicle': 'automobile', '차량': 'automobile', 'automobile': 'automobile',
    '자율주행': 'autonomous driving', 'autonomous driving': 'autonomous driving', 'autonomous vehicle': 'autonomous driving',
    '기계': 'machinery', 'machinery': 'machinery',
    '건설': 'construction', 'construction': 'construction', '공법': 'construction method',
    '건축': 'architecture', 'architecture': 'architecture',
    '설계': 'design', 'design': 'design',
    '시스템': 'system', '시스템 개발': 'system', 'system': 'system',
    'cfd': 'cfd', '전산유체역학': 'cfd', 'computational fluid dynamics': 'cfd',
    'fea': 'fea', '유한요소해석': 'fea', 'finite element analysis': 'fea', 'finite element method': 'fea',
    'ev': 'ev', '전기차': 'ev', 'electric vehicle': 'ev', 'electric vehicles': 'ev',
    'drone': 'drone', '드론': 'drone', 'uav': 'drone', 'unmanned aerial vehicle': 'drone',
    'iot': 'iot', '사물인터넷': 'iot', 'internet of things': 'iot',
    'bim': 'bim', 'building information modeling': 'bim',
    'vr': 'virtual reality', '가상현실': 'virtual reality', 'virtual reality': 'virtual reality',
    'ar': 'augmented reality', '증강현실': 'augmented reality', 'augmented reality': 'augmented reality',
    'metaverse': 'metaverse', '메타버스': 'metaverse',
    'digital twin': 'digital twin', '디지털 트윈': 'digital twin',
    'optimization': 'optimization', '최적화': 'optimization'
}
```

【 데이터 전처리 】

STEP 2. 불용어 사전

KYWD 기반 제목 추출 방식으로 결측치를 보간하여 노이즈를 일부 해결하였고,
남아있는 노이즈들에 대하여 불용어 사전을 제작하여 처리

```
stop_words = {  
    '기술', '논문', '한국', '동향', '연구 동향', '기술 동향', '연구동향', '기술동향', '학술대회',  
    '현황', '고찰', '검토', '활용', '정보', '계획', '전망', '전략', '산업', '융합', '개선',  
    '고려', '특성', '영향', '효과', '제안', '변화', '본', '대한', '관한', '통한', '위한',  
    '따른', '이용한', '사례', '시사점', '원고', 'manuscript', 'journal', '초록', '연구자',  
    '학위논문', '사용', 'editor', '신기술', '혁신', '분석', '활동', '중요성', '필요성',  
    'performance', 'evaluation', 'guidelines', 'reliability', 'numerical analysis',  
    '법원', '사회', '교육', '뉴스', '기업', '학생', '인터뷰', '인식', '이해', '태도', '참여', '가치',  
    '청소년', '대학생', '노인', '우울', '환자', '간호', 'nursing', 'elderly', 'depression',  
    'bmi', 'selfefficacy', 'job satisfaction', 'satisfaction', 'education', 'stress', 'mental health',  
    '서울', 'korea', 'en', 'ng', 'te', 'sion', 'ation', 'ra', 'ig', 'par', 'es', 'ph',  
    'ci', 're', 'as', 'he', 'co', 'no', 'ce', 'ut', 'ins', 'cti', 'ru', 'sub', 'et', 've'  
}
```

【 데이터 전처리 】

STEP 3. 사전 구축

기존 키워드 대문자를 소문자로 만들기
(ex. Deep Learning → deep learning)

긴 단어부터 정렬
(단어의 쪼개짐 방지)

키워드 중복 삽입 방지
(deep learning이 2개 들어가는 경우)

```
# 사전 구축(긴 단어 우선)
all_raw_kws = []
for k in df[df['KYWD'] != '']['KYWD']:
    parts = [p.strip().lower() for p in str(k).split(',') if len(p.strip()) > 1]
    all_raw_kws.extend(parts)
master_vocab = sorted(list(set(all_raw_kws)), key=len, reverse=True)
```

【 데이터 전처리 】

STEP 4. 키워드 추출

키워드가 없는 논문의 경우 제목을 분석하여
앞에서 구축한 사전을 토대로 키워드 추출.

긴 단어부터 매칭한 후, 매칭된 단어는 지우는 식으로
추출하여 정밀도 확보.

```
# 제목에서 키워드 추출
missing_mask = (df['KYWD'] == '')
for title in df.loc[missing_mask, 'NODE_TITLE']:
    if pd.notnull(title):
        title_clean = str(title).lower()
        extracted = []
        for word in master_vocab:
            if word in title_clean:
                extracted.append(word)
                title_clean = title_clean.replace(word, " ") # 파편화 방지
```

【 데이터 전처리 】

STEP 5. 빈도수 계산

기존에 존재하던 키워드와
제목에서 추출해낸 키워드 빈도수 계산

```
# KYWD 컬럼 집계
for kw in all_raw_kws:
    std_name = mapping_dict.get(kw, kw)
    if std_name not in stop_words and len(std_name) > 1:
        final_counts[std_name] += 1
```

```
# 제목에서 복구한 키워드 집계
for kw in extracted:
    std_name = mapping_dict.get(kw, kw)
    if std_name not in stop_words and len(std_name) > 1:
        final_counts[std_name] += 1
```


【 데이터 전처리 결과 】

1	deep learning	2,614회
2	ai	1,546회
3	machine learning	1,347회
4	system	567회
5	data	491회
6	automobile	481회
7	drone	457회
8	metaverse	456회
9	iot	412회
10	object detection	411회
11	virtual reality	391회
12	design	378회
13	optimization	334회
14	autonomous driving	326회
15	cnn	312회
16	machinery	309회
17	fea	307회
18	augmented reality	307회
19	covid-19	306회
20	설비	305회
21	neural network	298회
22	construction	271회
23	전력	269회
24	digital twin	257회
25	에너지	253회
26	shipbuilding	251회
27	발전	248회

28	콘크리트	232회
29	reinforcement learning	231회
30	탄소중립	224회
31	blockchain	215회
32	cfđ	215회
33	convolutional neural network	213회
34	환경	211회
35	lstm	210회
36	computer vision	202회
37	generative ai	195회
38	simulation	192회
39	anomaly detection	189회
40	text mining	186회
41	data augmentation	178회
42	image processing	173회
43	ev	173회
44	architecture	173회
45	도시	166회
46	통신	160회
47	transformer	158회
48	해양	158회
49	제어	156회
50	안전	155회
51	로봇	154회
52	digital forensics	154회
53	특허	151회
54	topic modeling	148회

【 데이터 전처리 결과 】

총 49,584명의 연구자를 식별.							
	AUTR_NM	PLCT_NM	전체논문수	최근연구연도	최근3년_활동량	동명이인_의심_수	
0	이진천	설비저널	61	2025	37	1	
1	김의중, 조흥현	설비저널	60	2025	36	1	
2	김현	대한토목학회지	59	2025	35	4	
3	신현배	기계저널	59	2025	35	1	
4	조흥	대한토목학회지	59	2025	35	1	
5	이창식	오토저널	57	2025	35	2	
6	이상운	한국인터넷방송통신학회 논문지	54	2025	34	1	
7	박만재	기계저널	33	2025	29	1	
8	문지영	대한토목학회지	26	2025	25	1	
9	구상	한국자동차공학회논문집	31	2025	22	2	
10	김태용	오토저널	22	2025	22	3	
11	백우진	대한토목학회지	22	2024	22	1	
12	김동권	설비저널	30	2025	18	1	
13	김정진	기계저널	30	2025	18	2	
14	정민영	대한토목학회지	30	2025	18	2	
15	김종현	한국컴퓨터정보학회논문지	22	2025	18	7	
16	서사범	철도저널	29	2025	17	1	
17	송달호	철도저널	29	2025	17	1	
18	신종선	대한토목학회지	29	2025	17	2	
19	유지이	기계저널	29	2025	17	1	
결과 파일 저장 완료: /content/drive/MyDrive/진짜_연구자_전수분석_리포트.csv							

	clean_plct	total_cnt	ai_ratio
91	지능정보연구	288	26.74
15	Journal of Computing Science and Engineering	98	23.47
134	한국지능시스템학회 논문지	365	22.74
56	멀티미디어학회논문지	791	19.85
57	방송공학회논문지	405	19.75
127	한국전자거래학회지	204	17.65
130	한국정보기술학회논문지	1153	17.26
133	한국정보통신학회논문지	1132	17.23
96	컴퓨터그래픽스학회논문지	140	16.43
82	정보과학회 컴퓨팅의 실제 논문지	458	16.16

[지표 1] 공학 분야별 전체 논문 갯수

공학 분야	전체 논문 갯수
0 전기전자공학	18255
1 기계공학	12666
2 건축공학	11464
3 컴퓨터학	6831
4 공학 일반	5569
5 기타 공학	1984
6 화학공학	1444
7 재료·에너지공학	1408
8 산업공학	1392
9 조선해양공학	1186

[지표 2] 연도별 분야별 논문 증가 갯수

field	건축공학	공학 일반	기계공학	기타 공학	산업공학	재료·에너지공학	전기전자공학	조선해양공학	컴퓨터학	화학공학
year										
2021	0	0	0	0	0	0	0	0	0	0
2022	-69	-38	-44	-29	12	-9	44	33	11	-26
2023	-32	-23	-26	-32	-2	4	-118	0	78	-6
2024	44	88	46	18	-20	-26	247	-1	93	-26
2025	-262	-26	-347	-75	-55	-56	-546	16	-268	-47

[지표 3] 연도별 분야별 논문 증가율

field	건축공학	공학 일반	기계공학	기타 공학	산업공학	재료·에너지공학	전기전자공학	조선해양공학	컴퓨터학	화학공학
year										
2021	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
2022	-2.87	-3.37	-1.67	-6.49	4.15	-2.92	1.19	15.87	0.83	-2.60
2023	-1.37	-2.11	-1.00	-7.66	-0.66	1.34	-3.15	0.00	5.83	-0.40
2024	1.91	8.25	1.79	4.66	-6.69	-8.58	6.82	-0.41	6.57	-2.60
2025	-11.17	-2.25	-13.29	-18.56	-19.71	-20.22	-14.11	6.67	-17.76	-1.83

field	화학공학
year	
2021	0.00
2022	-7.81
2023	-1.95
2024	-8.64
2025	-17.09

[지표 4] 공학 분야별 AI 연구 논문 총 갯수

공학 분야	AI 연구 논문 총수
0 건축공학	1415
1 공학 일반	1081
2 기계공학	1877
3 기타 공학	508
4 산업공학	507
5 재료·에너지공학	285
6 전기전자공학	4747
7 조선해양공학	136
8 컴퓨터학	1981
9 화학공학	68

[지표 5] 연도별 분야별 AI 연구 증가 갯수

field	건축공학	공학 일반	기계공학	기타 공학	산업공학	재료·에너지공학	전기전자공학	조선해양공학	컴퓨터학	화학공학
year										
2021	0	0	0	0	0	0	0	0	0	0
2022	25	-22	-19	-15	-9	2	19	5	-19	5
2023	-8	18	-28	7	1	1	19	-4	56	-8
2024	21	48	29	3	13	-14	163	-4	57	0
2025	17	14	-16	26	-16	-3	-87	11	-25	7

[지표 6] 연도별 분야별 AI 연구 증가율

field	건축공학	공학 일반	기계공학	기타 공학	산업공학	재료·에너지공학	전기전자공학	조선해양공학	컴퓨터학	화학공학
year										
2021	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
2022	9.77	-10.95	-4.76	-14.56	-8.49	3.29	2.17	20.00	-5.28	39.46
2023	-2.85	10.06	-7.37	7.95	1.03	1.59	2.13	-13.33	16.42	-44.44
2024	7.69	24.37	8.24	3.16	13.27	-21.88	17.85	-15.38	14.36	0.00
2025	5.78	5.71	-4.20	26.53	-14.41	-6.00	-8.09	50.00	-5.51	70.00

[지표 7] 연도별 전체 논문 대비 AI 연구 비율

field	건축공학	공학 일반	기계공학	기타 공학	산업공학	재료·에너지공학	전기전자공학	조선해양공학	컴퓨터학	화학공학
year										
2021	10.66	17.82	15.14	23.04	36.68	19.81	23.67	12.02	27.13	0.00
2022	12.04	16.42	14.67	21.05	32.23	21.07	23.90	12.45	25.49	-2.60
2023	11.86	19.46	13.72	24.61	32.79	21.12	25.20	10.79	28.04	-0.40
2024	12.54	21.21	14.59	24.26	39.78	18.05	27.80	9.17	30.09	-2.60
2025	14.93	22.94	16.12	37.69	42.41	21.27	29.75	12.89	34.57	-1.83

field	화학공학
year	
2021	3.90
2022	5.86
2023	3.32
2024	3.64
2025	7.46

【 데이터 분석 】 학제간 분석

(A) AI 도입 속도가 가장 빠른 분야

- 분석 결과: AI 비중 증가폭이 가장 큰 분야는 "산업공학"(8.22%p)으로 나타났으며, 컴퓨터학(4.88%p)과 전기전자공학(3.92%p)이 그 뒤를 이음

(B) AI-전통 방법론 패러다임

- 분석 결과: 2021년 대비 2025년 기준, Pure AI(대체) 연구가 약 2,133건에서 2,353건으로 증가하는 동안 Fusion(융합) 연구 역시 249건에서 299건으로 꾸준히 동반 성장하고 있음

(C) H/W 설계 vs S/W AI 연구 비중

- 분석 결과: 전기/제어 분야에서 SW 중심 AI 연구(984건)가 HW 설계 연구(352건) 대비 약 2.8배에 달하는 압도적인 비중을 차지하고 있음

(A) AI 도입 속도가 가장 빠른 분야 (TOP 5):
AI비중_증가폭(%P)

field	
산업공학	8,223484
컴퓨터학	4,882365
공학 일반	4,611780
전기전자공학	3,919629
기타 공학	3,204794

(B) AI-전통 방법론 연구 패러다임 변화:

type	Fusion(융합)	Pure AI(대체)	Pure Traditional(전통)
year			
2021	249	2133	729
2022	229	2119	748
2023	241	2162	791
2024	257	2468	849
2025	299	2353	790

(C) H/W 설계 vs S/W AI 연구 건수 추이 (전기/제어 분야):


	HW_설계_연구	SW_AI_연구
year		
2021	385	866
2022	387	879
2023	341	898
2024	380	1061
2025	352	984

모든 분석 완료! 엑셀 파일 다운로드: Engineering_AI_Full_Report_Final.xlsx

[데이터 분석] 기술 변곡점 및 사회적 이슈 영향 분석


A) 기술의 변곡점: "분석에서 생성으로, 2023년의 패러다임 변화"

- 분석 결과: 2020년 이전까지는 사물을 감지하고 분류하는 "분석형 AI(Object Detection)"가 주류였으나, 2023년을 기점으로 LLM (거대 언어 모델) 기반의 '생성형 AI(Generative AI)' 관련 키워드가 폭발적으로 증가하며 주도권을 잡았다.




(B) 사회적 이슈의 영향: "COVID-19가 당긴 비대면과 탄소중립의 가속"

- 분석 결과: COVID-19 이후 비대면 제어, 원격 모니터링 키워드가 급증했으며, 최근에는 탄소중립(Net Zero) 목표 달성을 위한 "디지털 트윈(Digital Twin)"과 에너지 최적화 연구가 공학 데이터의 핵심 키워드로 부상했다.



[데이터 분석] 급상승 키워드 관련 우수 연구자 및 발행기관 분석

A: Researcher Composition (Newcomer vs Veteran)




(A) 연구 주체 분석: "신진 연구자(Newcomer)가 이끄는 기술 혁신"

- 분석 결과: 생성형 AI, LLM 등 급상승 키워드 연구자의 "82.4%"가 2022년 이후 등판한 신진 연구자로 나타났다.

(B) 산학 협력 동향: "실무 중심의 Deep Learning vs 전략 중심의 LLM"

- 분석 결과: 산업체 참여율이 가장 높은 키워드는 "Deep Learning(8.1%)"이었으며, "LLM(6.2%)"과 "Autonomous Driving(5.7%)"이 그 뒤를 이었다. 반면 "Digital Twin(3.4%)"은 상대적으로 학계 중심의 연구가 주를 이루고 있다.

B: Industry Participation Rate (Max 14%)



[아이디어 개요]



"4bit: Pathfinder - 고해상도 공학 연구 트렌드 분석을 위한 지능형 내비게이터"

1. 프로젝트 배경 및 문제 정의: DBpia로부터 추출된 62,199건의 방대한 공학 분야 학술 메타데이터를 분석 대상으로 함. 기존 데이터에는 연구실 홍보, 학회 일정 등 행정적 노이즈가 혼재되어 있으며, 키워드 필드의 약 26.38%가 결측된 상태로 정밀한 트렌드 분석에 한계가 있음.

2. 핵심 아이디어: Pathfinder

- 지능형 연구 경로 탐색: 단순 키워드 검색을 넘어, 데이터 속의 노이즈를 박멸하고 연구자에게 가장 가치 있는 연구의 길을 보여주는 지능형 어드바이저 시스템 구축.
- 데이터 해상도 증대: 결측치 복구 알고리즘과 다단계 정제 로직을 통해 데이터의 해상도를 높여, 숨겨진 연구 흐름을 선명하게 도출함.

3. 기대 효과 및 시사점: 연구 효율성 극대화

- 초보 연구자가 특정 키워드 하나로 해당 분야의 우수 연구자, 핵심 학술지, 최신 트렌드를 즉각 식별할 수 있게 함.



"Pathfinder 엔진: 데이터 노이즈 제거 및 의미론적 탐색 로직 구현"

1. 시스템 아키텍처 구동 및 환경: Python 기반 Streamlit 라이브러리를 활용하여 연구자용 대화형 Adviser UI를 구축하고, Faiss 엔진을 탑재하여 62,199건의 대규모 학술 데이터를 실시간으로 탐색하는 고속 검색 백엔드 설계
2. 데이터 노이즈 제거 알고리즘: 기술적 실체가 있는 순수 연구물만을 선별하고 검색어를 표준 용어로 정규화
3. S-RoBERTa 기반 지능형 경로 탐색: ko-sroberta-multitask 모델을 활용한 의미론적 유사도 분석을 통해, 사용자가 입력한 키워드가 논문 제목이 일치하지 않더라도 연구의 맥락과 기술적 연관성을 파악하여 최적의 논문을 추천함

← ↻ ⓘ localhost:8504

4bit: Pathfinder

복잡한 논문 더미 속에서 연구의 길을 찾아준다

62,199건의 공학 지식 베이스를 정밀 분석하여 최적의 연구 경로를 탐색합니다.

준비 완료: 분석하고 싶은 공학 기술 키워드를 입력하고 엔터를 누르세요.

탐색할 기술 키워드 입력

예: 자율주행, 반도체 설계, 에너지 공학

【 모델링 / 분석 방법 】

```
File Edit Format Run Options Window Help
import streamlit as st
import pandas as pd
import faiss
import pickle
import os
from sentence_transformers import SentenceTransformer

# 1. UI 설정 및 페이지 브랜딩 (영문 타이틀 적용)
st.set_page_config(page_title="4bit Pathfinder", layout="wide")

@st.cache_resource
def load_resources():
    idx_path = '4bit_engineering_papers.index'
    meta_path = '4bit_metadata.pkl'
    if os.path.exists(idx_path) and os.path.exists(meta_path):
        idx = faiss.read_index(idx_path)
        with open(meta_path, 'rb') as f:
            meta = pickle.load(f)
        model = SentenceTransformer('jhgah/ko-sroberta-multitask')
        return idx, meta, model
    return None, None, None

# 영문 메인 타이틀 고정
st.title("4bit Pathfinder")
st.subheader("복잡한 논문 더미 속에서 연구의 길을 찾아준다")
st.write("62,199건의 공학 지식 베이스를 정밀 분석하여 최적의 연구 경로를 탐색합니다.")

idx, meta, model = load_resources()

# 2. 검색어 자동 최적화 사전
query_mapping = {
    "화학": "화학공학",
    "전기": "전기전자공학",
    "전자": "전기전자공학",
    "건축": "건축공학"
}
```

```
3. 메인 서비스 로직
idx is not None:
    # [UI 복원] 파란색 준비 완료 안내 바
    st.info("준비 완료: 탐색할 기술 키워드를 입력하고 엔터를 누르세요.")
    user_query = st.text_input("기술 키워드 입력", placeholder="예: 자율주행, 반도체 설계, 에너지 공학")

    if user_query:
        # 검색어 보정 적용
        refined_query = query_mapping.get(user_query.strip(), user_query)

        with st.spinner("Pathfinder 알고리즘이 최적의 경로를 분석 중입니다..."):
            q_vec = model.encode([refined_query])
            D, I = idx.search(q_vec.astype('float32'), 500)
            res = meta.iloc[I[0]].copy()

            # [노이즈 차단] 행정/비연구 데이터 필터링
            exclude_words = [
                '소개', '안내', '공지', '일정', '특집', '회보', '도약기', '보고서', '부처',
                '머리말', '축사', '목차', '축복', '창사', '감사', '연구실', 'Lab', '소식',
                '동정', '인사', '개정', '발자취', '기여', '서문', 'ARTICLE', '말씀', '뒷단배'
            ]

            # 제목 길이 및 금지어 필터링
            res = res[res['NODE_TTLE'].str.len() > 12]
            res = res[~res['NODE_TTLE'].str.contains('|'.join(exclude_words), case=False, na=False)]
            res = res[~res['AUTR_NM'].str.contains('편집부', na=False)]
            res = res.drop_duplicates(subset=['NODE_TTLE'], keep='first')

            # 검색된 양질의 논문 총 건수 계산
            total_found = len(res)
            # 가변 결과 출력 (많으면 최대 10개)
            final_res = res.head(10)
```

```
if not final_res.empty:
    st.write("----")

    # [UI] 검색 결과 건수를 작고 검은 글씨로 표시
    st.markdown(f"### '{user_query}' 분석 리포트 <span style='color: black; font-weight: normal; font-size: 14px; margin-left: 10px;'>{total_found}건")

    # [UI] 전문적인 3단 지표 섹션
    m1, m2, m3 = st.columns(3)
    m1.metric("최적 연구 분야", final_res['NODE_CLSS_02'].value_counts().idxmax())
    m2.metric("핵심 연구자", final_res['AUTR_NM'].value_counts().idxmax())
    m3.metric("주요 연구 주제", final_res['org_type'].value_counts().idxmax())

    st.write(f"#### Pathfinder가 제안하는 상위 {len(final_res)}개의 핵심 연구 정보")

    # [UI] 상세 정보 확장창 섹션 (Expander)
    for i, (_, row) in enumerate(final_res.iterrows(), 1):
        with st.expander(f"순위 {i}: {row['NODE_TTLE']}"):
            c1, c2 = st.columns(2)
            with c1:
                st.write(f"***주요 저자:** {row['AUTR_NM']}")
                st.write(f"***소속 기관:** {row['clean_plct']}")
            with c2:
                st.write(f"***연구 분야:** {row['NODE_CLSS_02']}")
                st.write(f"***기관 성격:** {row['org_type']}")
            # 키워드 데이터 출력
            st.write(f"***핵심 키워드:** {', '.join(row['final_kywd'])}")

    else:
        st.warning(f"'{refined_query}'와 관련된 순수 기술 데이터가 현재 베이스에 없습니다.")
else:
    st.error("오류: 모델 파일이 같은 폴더에 없습니다. 경로를 확인하세요.")
```



1. 리소스 로드 및 초기 설정 (load_resorces): FAISS 엔진 로드 (4bit_engineering_papers.index을 불러와 6만 건의 데이터 중 사용자의 질문과 가장 유사한 논문을 순식간에 찾아냄), 메타데이터 로드 (4bit_metadata.pk1), S-RoBERTa 모델 (단순한 키워드 매칭을 넘어선 의미 기반 검색을 가능하게 함)

2. 검색어 자동 보정

3. 지능형 노이즈 제거: 데이터 정제 로직('소개', '안내', '공지' 등 기술적 실체가 없는 행정적 노이즈 단어를 선별하여 검색 결과에서 원천 배제), 구조적 필터링 (제목이 너무 짧은 데이터나 편집부가 작성한 비논문식 자료를 필터링)

[모델링 결과 해석 & 활용 방안]



← ↻ ⓘ localhost:8503

4bit: Pathfinder

복잡한 논문 더미 속에서 연구의 길을 찾아준다

62,199건의 공학 지식 베이스를 정밀 분석하여 최적의 연구 경로를 탐색합니다.

준비 완료: 분석하고 싶은 공학 기술 키워드를 입력하고 엔터를 누르세요.

탐색할 기술 키워드 입력

전자

'전자' 분석 리포트 (검색된 양질의 논문: 412건)

최적 연구 분야

전기전자공학

핵심 연구자

이종환, 정인환

주요 연구 주제

Research

Pathfinder가 제안하는 상위 10개의 핵심 연구 정보

> 순위 1: 미래 전장의 핵심전력, 전자전기 개발동향

> 순위 2: 반도체변압기와 전력전자기술

> 순위 3: 전동기제어를 위한 전력전자공학 교육

> 순위 4: 전기자동차용 전력반도체 기술동향

> 순위 5: 전기자기 센서기술 기술동향

> 순위 6: 전력전자와 Spread Spectrum

> 순위 7: Development of Stretchable Electronics Using Geometric Strategies and Applications

"데이터 해상도 증대를 통한 정밀 연구 트렌드 식별"

- 기존 검색 엔진에서 상위에 노출되던 '연구실 홍보글'이나 '학회 인사말' 등을 차단하고 순수 연구 논문 위주로 결과 재구성
- 데이터 기반 인사이트: 양질의 논문 식별. 필터링 후 남은 '실제 연구물'의 건수를 사용자에게 시각적으로 제공하여 추천의 신뢰성 확보
- 결과: 검색 시 다른 분야로 튜는 현상을 방지하고, 검색 분야의 상위 전문가 및 핵심 연구 분야를 도출

21

[모델링 결과 해석 & 활용 방안]



"데이터 기반 신뢰도 지표 제공 & 분야 간 경로 및 핵심 전문가 식별"

- Pathfinder의 정밀 필터링을 거쳐 선별된 446건의 '양질의 논문' 수치를 제시하여, 단순 키워드 매칭이 아닌 데이터적 근거에 기반한 추천의 신뢰성 확보
- 핵심 연구자 및 융합 트렌드 식별: 머신러닝 기술이 '전기전자공학' 분야와 결합되는 최신 융합 트렌드를 포착하고, 해당 분야 핵심 연구자 및 연구 주체 정보를 정밀 도출

← ↻ ⓘ localhost:8501

4bit: Pathfinder

복잡한 논문 더미 속에서 연구의 길을 찾아준다

62,199건의 공학 지식 베이스를 정밀 분석하여 최적의 연구 경로를 탐색합니다.

준비 완료: 탐색할 기술 키워드를 입력하고 엔터를 누르세요.

기술 키워드 입력

머신러닝

최적 연구 분야

전기전자공학

핵심 연구자

김환진

주요 연구 주체

Research

Pathfinder가 제안하는 상위 10개의 핵심 연구 정보

> 순위 1: 머신러닝 기반 채널 예측 기법 연구 동향

> 순위 2: 머신러닝을 활용한 공조부하계산의 확장

> 순위 3: ChatGPT를 활용한 머신 러닝 회귀 모델의 효율적 개발

> 순위 4: 머신러닝을 이용한 인터리버 제원 블라인드 추정

> 순위 5: 머신러닝을 이용한 고속 인터커넥 설계

> 순위 6: 머신러닝 기술을 이용한 사이버위협 대응 방안에 관한 연구

> 순위 7: 머신러닝 기반의 안전도 데이터 필터링 모델

22

【 한계점 및 개선 방향 1 】

데이터 전처리의 기술적 한계

한계점 현재 코드는 긴 단어 우선 매칭 방식을 사용하기에 문맥에 따라 단어의 의미가 변하는 다의어 처리에 취약함.

제목에서 키워드를 추출할 때 replace를 사용해 빈칸으로 치환하는 과정에서 합성어나 복합 명사가 쪼개져 의미가 왜곡될 가능성이 있음.

현재 140여 개의 불용어를 수동으로 지정했으나, 공학 도메인의 방대함을 고려할 때 여전히 걸러지지 않은 노이즈 데이터가 존재함.

개선방향 단순 문자열 치환을 넘어 Okt나 soynlp의 형태소 분석 기능을 강화하여 공학 용어의 원형을 보존하는 정교한 토큰화 구현.

$$TF-IDF(t, d, D) = tf(t, d) \times idf(t, D)$$

수동 불용어 처리 대신 단어 빈도-역문서 빈도를 계산하여 통계적으로 유의미한 키워드 자동 선별.

연구자 식별 및 소속 기관 매칭의 한계

한계점 이름과 소속 기관이 같으면 동일인으로 간주하거나, 실제로는 같은 대학 내 같은 이름을 가진 연구자가 존재할 수 있어 완전한 분리에 한계가 있음.

동일 기관임에도 불구하고 '서울대학교', 'SNU', 'Seoul Natl Univ' 등으로 기관명 표기가 파편화되어 있어 산학 협력 지표 산출 시 수치가 분산됨.

개선방향 저자의 고유 ID(ORCID 등)가 있다면 이를 연동하고, 없을 경우 연구 주제(키워드) 유사도를 기반의 저자 동일성 검증 로직 추가.

정규표현식을 넘어선 외부 기관명 API 연동을 통한 표준화 작업 도입 검토.

【 한계점 및 개선 방향 2 】

추가적인 현재 시스템의 한계

한계점 메타데이터 결측치 문제: 키워드 필드(KYWD)의 약 26.38% 결측치를 제목 매칭 로직으로 보완했으나, 초록 정보는 반영하지 않아 논문의 심층적인 맥락까지 완벽하게 파악하기는 어려움.

현재는 논문의 빈도와 유사도 중심으로 우수 연구자 및 경로를 제안하고 있으나, 인용 수(Citation)나 저널 영향력 지수(IF)와 같은 질적 평가 지표가 분석 로직에 포함되지 않음.

향후 개선 및 확장 방향

개선방향 실시간 학술 DB API 연동: DBpia 등 외부 학술 데이터베이스 API와 실시간으로 연동하여, 매일 업데이트되는 최신 연구 데이터를 자동으로 수집 및 벡터 인덱싱하는 파이프라인 구축.

RAG 기반 생성형 AI 도입: 단순한 논문 리스트 제공을 넘어, 검색된 상위 논문들의 핵심 내용을 LLM (거대언어모델) 이 직접 요약하고 연구자의 질문에 답변해 주는 'Retrieval-Augmented Generation' 기능 탑재.

글로벌 트렌드 분석 확장: 국문 데이터 중심에서 영문 논문 데이터셋으로 분석 범위를 확장하여, 글로벌 공학 기술 트렌드와의 비교 분석 및 글로벌 공동 연구 네트워크 탐색 기능 추가.

【 결론 】

데이터 신뢰성 확보

누락 데이터의 제목 기반 키워드 추출을 통한 데이터 가치 극대화

문제 해결: 기존 공학 논문 데이터의 핵심이었던 키워드(KYWD) 결측치 26.38%를 단순 무시하지 않고, 제목(NODE_TITLE) 기반의 키워드 추출을 통해 정밀 복원

성과: 마스터 사전 구축을 통해 결측치의 약 77%를 복구하여(충전율 94%) 전수 분석이 가능한 수준의 무결성 높은 데이터셋을 확보

```
-----  
결측치 복구 성공률   : 77.39%  
최종 데이터 충전율   : 94.0%  
=====
```

【 결론 】

기술 변곡점의 포착 : AI 연구의 판도 변화

2023년 기점으로 AI 연구의 트렌드가 분석형 AI → 생성형 AI로 전환되는 변곡점을 포착

최신 기술 연구의 82.4%가 2022년 이후 등장한 신진 연구자들에 의해 주도되고 있음을 포착

→ 공학계의 역동성과 세대교체 증명

【 결론 】

시스템적 가치: "4bit Pathfinder"를 통한 연구 효율 극대화

- : 단순 검색을 넘어선 추천 → 단순히 과거 데이터를 조회하는 수준을 넘어, 사용자가 입력한 키워드에 대해 최적의 연구 분야, 전문가, 협력 기관을 즉각적으로 추천하는 분석 엔진을 구현함
- : 의미론적 탐색: S-ROBERTa 모델과 Faiss 엔진을 결합하여, 제목이 키워드와 정확히 일치하지 않더라도 기술적 맥락을 파악해 최적의 연구 경로를 제안하는 지능형 시스템을 구축함

향후 과제 및 비전: 실시간 글로벌 연구 어드바이저로의 진화

- : 향후 RAG(Retrieval-Augmented Generation, 검색 증강 생성) 기능을 탑재하여 논문 리스트 제공을 넘어, 검색된 논문의 핵심 내용을 LLM이 요약하고 질문에 답변해 주는 기능을 탑재
- : 국문 데이터를 넘어 글로벌 데이터셋으로 분석 범위를 확장하여, 전 세계 공학 트렌드를 실시간으로 모니터링하고 예측하는 글로벌 연구 파트너로 성장 가능성 있음

4bit Pathfinder

복잡한 논문 더미에서 연구의 길을 찾아준다.